SoftITO Yazılım – Bilişim Akademisi

4. Dönem 3. Grup · Veri Analitiği Eğitimi

E-Ticaret Veri Akışları Üzerinde Medallion Veri Ambarı, Gerçek Zamanlı Olay İzleme ve Zamansal Havuzlama Tabanlı Müşteri Kaybı Tahmini

Bitirme Projesi Raporu

Hazırlayan: Şerife Sena Özişci

Tarih: Kasım, 2026

İÇİNDEKİLER

Bölüm Başlığı	Kapsam
ÖZET	Yönetici Özeti ve Anahtar Kelimeler
1. GİRİŞ	Problem Tanımı ve Kapsam
1.1. Çalışmanın Amacı ve Önemi	Bölüm 1.1
1.2. Problem Tanımı ve İş Bağlamı	Bölüm 1.2
1.3. Çalışmanın Kapsamı ve Sınırlılıkları	Bölüm 1.3
2. LİTERATÜR ÖZETİ	Kuramsal Çerçeve ve İlgili Çalışmalar
3. MATERYAL VE METOT	Mimari, ETL ve Modelleme
3.1. Veri Seti ve Medallion Veri Ambarı	Tablo 1
3.2. Eksik Veri Analizi ve ETL Dönüşümleri	Bölüm 3.2
3.3. Gerçek Zamanlı Olay Akışı ve Servis Katmanı	Bölüm 3.3
3.4. Keşifsel Veri Analizi ve Kohort Tasarımı	Şekil 1, Şekil 2
3.5. K-Means Tabanlı RFM Müşteri Segmentasyonu	Bölüm 3.5
3.6. Zamansal Havuzlama (Sliding Window) ve Sızıntı Koruması	Bölüm 3.6
3.7. Sınıflandırma Algoritmaları ve Hiperparametre Yapılandırması	Bölüm 3.7
4. BULGULAR	Deneysel Sonuçlar ve Analiz
4.1. Keşifsel Veri Analizi Bulguları	Bölüm 4.1
4.2. RFM Kümeleme Bulguları	Tablo 2, Şekil 3
4.3. Tek Kesit ve Zamansal Havuzlama Karşılaştırması	Tablo 3
4.4. Makine Öğrenmesi Modellerinin Karşılaştırılması	Tablo 4, Şekil 4, Şekil 5
4.5. Öznitelik Önem Düzeyleri	Şekil 6
5. SINIRLILIKLAR VE METODOLOJİK DEĞERLENDİRME	Bölüm 5
6. SONUÇ VE GELECEK GELİŞTİRMELER	Bölüm 6
KAYNAKÇA	APA 7. Edisyon Kaynak Listesi

ÖZET

Bu çalışmada, çok satıcılı elektronik ticaret ortamlarındaki operasyonel veri akışlarını bütünleşik biçimde işleyen ve tekrar alışveriş yapan müşterilerin platformu terk etme (churn) olasılığını tahmin eden uçtan uca bir veri mühendisliği ve analitiği sistemi geliştirilmiştir. Araştırmada Brezilya e-ticaret ekosistemine ait Olist veri seti kullanılmış; 99.441 sipariş, 112.650 sipariş kalemi, 103.886 ödeme, 99.224 müşteri değerlendirmesi ve 32.951 ürün kaydı PostgreSQL üzerinde üç katmanlı Medallion mimarisi (Bronze, Silver, Gold) ile yapılandırılmıştır. Ayrıca Apache Kafka tabanlı bir olay akışı (streaming) hattı kurularak anlık sipariş simülasyonu ve FastAPI destekli gerçek zamanlı model çıkarım servisi oluşturulmuştur.

Keşifsel veri analizi aşamasında toplam 95.774 tekil müşterinin %96,89'unun (92.799 kişi) yalnızca tek bir sipariş verdiği, yalnızca %3,11'inin (2.975 kişi) en az iki sipariş verdiği tespit edilmiştir. Bu bulgu doğrultusunda müşteri kaybı modellemesi, tekrar satın alma davranışı gösteren müşteriler kohortu üzerinde 180 günlük takip penceresi ile kurgulanmıştır. Tek bir kesit tarihine (2018-03-04) dayalı örneklemin 1.753 kayıtla sınırlı kalması ve mevsimsel dalgalanmaları yansıtmaması nedeniyle üç farklı tarihten (2017-10-01, 2017-12-15 ve 2018-03-04) kesit alan Zamansal Havuzlama (Sliding Window) yaklaşımı uygulanmış ve veri hacmi 3.678 satıra çıkarılmıştır. Aynı müşterinin hem eğitim hem test kümesinde yer alarak bilgi sızıntısı (data leakage) oluşturmasını önlemek amacıyla müşteri kimliği bazında grup ayrımı (GroupShuffleSplit) uygulanmış ve örtüşme sıfır olarak doğrulanmıştır.

Dengesiz sınıf dağılımını yönetmek üzere sınıf ağırlıklandırması (scale_pos_weight = 0,0423) ile eğitilen XGBoost modeli, genişletilmiş 723 örnekli test kümesinde 0,7398 ROC-AUC, 0,9781 PR-AUC, 0,8998 F1-Score ve %82,30 doğruluk (accuracy) elde ederek üretim modeli olarak seçilmiştir. Ek olarak 93.106 geçerli müşteri üzerinde K-Means algoritması ile dört segmentli RFM profili çıkarılmıştır. Çalışma, yüksek sınıf dengesizliği barındıran e-ticaret verilerinde tekil doğruluk metriği yerine ROC-AUC, PR-AUC ve azınlık sınıfı ayırt etme kapasitesinin birlikte değerlendirilmesi gerektiğini ortaya koymaktadır.

Anahtar Kelimeler: *Müşteri kaybı tahmini, Medallion mimarisi, zamansal havuzlama, XGBoost, RFM segmentasyonu, Apache Kafka, sınıf dengesizliği.*

1. GİRİŞ

1.1. Çalışmanın Amacı ve Önemi

Elektronik ticaret pazar yerlerinde müşteri kazanım maliyetlerinin sürekli artması, mevcut müşterilerin platformda tutulmasını (retention) stratejik bir zorunluluk hâline getirmiştir. Ancak modern e-ticaret operasyonlarında veri; geçmiş sipariş kayıtlarını barındıran ilişkisel tablolardan, anlık sipariş olaylarından ve lojistik teslimat günlüklerinden eş zamanlı olarak akmaktadır. Bu heterojen veri kaynaklarının temizlenmeden veya zamansal bütünlüğü korunmadan doğrudan makine öğrenmesi modellerine beslenmesi, üretim ortamında yüksek sapmalara ve veri sızıntısına yol açmaktadır.

Bu bitirme projesinin temel amacı; ham e-ticaret verilerini katmanlı bir veri ambarında işleyen, gerçek zamanlı olay akışını destekleyen, müşterileri davranışsal değerlerine göre segmentlere ayıran ve tekrar alışveriş yapan müşterilerin platformu terk etme riskini yüksek genelleme gücüyle tahmin eden bütünleşik bir analitik platform geliştirmektir. Çalışma, veri mühendisliği altyapısı ile makine öğrenmesi deney tasarımını tek bir mimari çatı altında birleştirmesi bakımından önem taşımaktadır.

1.2. Problem Tanımı ve İş Bağlamı

Pazar yeri tabanlı e-ticaret platformlarında abonelik tabanlı telekomünikasyon veya bankacılık sektörlerinden farklı olarak açık bir "sözleşme feshi" anı bulunmamaktadır. Müşterinin platformu terk edip etmediği (non-contractual churn), belirli bir gözlem penceresi içerisinde yeni bir sipariş verip vermemesine göre tanımlanmaktadır. İncelenen veri setinde tekil müşterilerin %96,89'unun yalnızca bir kez alışveriş yapıp ayrıldığı gözlemlenmiştir. Tek seferlik alıcıların tamamını kayıp olarak etiketlemek, modelin tüm kitleye sabit biçimde pozitif sınıf atamasına ve operasyonel kampanya bütçelerinin verimsiz kullanılmasına neden olmaktadır.

Bu doğrultuda problem iki temel teknik soruna odaklanmaktadır: Birincisi, en az iki sipariş vermiş tekrar eden müşteriler (repeat customers) kohortunda 180 günlük takip penceresi içinde gerçekleşecek terk davranışını öngörmektir. İkincisi ise azınlık sınıfını oluşturan sadık müşterilerin (churn = 0) toplam örneklem içindeki payının %5'in altında kalması nedeniyle ortaya çıkan şiddetli sınıf dengesizliğini ve zamansal örnekleme darlığını gidermektir.

1.3. Çalışmanın Kapsamı ve Sınırlılıkları

Çalışma, açık erişimli Olist Brezilya e-ticaret veri seti üzerinde PostgreSQL, Apache Kafka, Python (Scikit-Learn, XGBoost, LightGBM), FastAPI, Streamlit ve Docker Compose teknolojileri kullanılarak yerel çoklu konteyner ortamında gerçekleştirilmiştir. Veri ambarı dönüşümleri Bronze, Silver ve Gold katmanları kapsamında yapılandırılmış; model çıkarım katmanı RESTful API uç noktaları üzerinden servis edilmiştir.

Veri setinin yapısı gereği müşterilere ait demografik (yaş, cinsiyet, gelir düzeyi) veya tıklama akışı (clickstream / sepet terk) günlükleri veri kaynağında yer almamaktadır. Dolayısıyla öznitelik mühendisliği yalnızca işlem sıklığı, parasal harcama, sipariş aralığı, ürün birim fiyatı ve müşteri değerlendirme puanları ile sınırlandırılmıştır.

2. LİTERATÜR ÖZETİ

Sözleşmesiz (non-contractual) perakende ve e-ticaret ortamlarında müşteri yaşam boyu değeri ve terk tahmini üzerine yapılan çalışmalar, büyük ölçüde RFM (Recency, Frequency, Monetary) çerçevesine dayanmaktadır. Fader vd. (2005), müşterilerin geçmiş satın alma sıklığı ve son işlem zamanının gelecekteki satın alma olasılığını belirlemede temel göstergeler olduğunu ortaya koymuştur. RFM metriklerinin gözetimsiz öğrenme yöntemleriyle birleştirilmesi konusunda ise MacQueen (1967) tarafından geliştirilen K-Means kümeleme algoritması, geniş ölçekli müşteri tabanlarının homojen davranış gruplarına ayrıştırılmasında yaygın biçimde kullanılmaktadır.

Müşteri kaybı tahmininde ağaç tabanlı topluluk (ensemble) öğrenme yöntemleri, doğrusal olmayan değişken etkileşimlerini yakalama kapasiteleri nedeniyle klasik istatistiksel modellere kıyasla üstün sonuçlar vermektedir. Breiman (2001) tarafından önerilen Rastgele Orman (Random Forest) algoritması yüksek varyans direnci sağlarken; Chen ve Guestrin (2016) tarafından geliştirilen XGBoost ve Ke vd. (2017) tarafından sunulan LightGBM mimarileri, gradyan artırma (gradient boosting) ve düzenlileştirme mekanizmaları sayesinde tablosal verilerde yüksek ayrım gücü sunmaktadır.

Bununla birlikte literatürde, sınıf dengesizliği barındıran ikili sınıflandırma problemlerinde yalnızca doğruluk (accuracy) metriğinin değerlendirilmesinin yanıltıcı sonuçlar doğurduğu vurgulanmaktadır (Chawla vd., 2002; Saito ve Rehmsmeier, 2015). Saito ve Rehmsmeier (2015), pozitif ve negatif sınıflar arasında yüksek oransal fark bulunduğunda Hassasiyet-Duyarlılık Eğrisi Altındaki Alan (PR-AUC) ve ROC-AUC metriklerinin birlikte raporlanması gerektiğini göstermiştir. Modern veri mühendisliği mimarilerinde ise ham verinin aşamalı olarak temizlenip analitik modellere dönüştürülmesi için Medallion katmanlı veri ambarı yaklaşımı (Armbrust vd., 2020) ve gerçek zamanlı olay işleme için dağıtık günlük sistemleri (Kreps vd., 2011) standart mimari bileşenler olarak benimsenmiştir.

3. MATERYAL VE METOT

3.1. Veri Seti ve Medallion Veri Ambarı Mimarisi

Çalışmada Brezilya merkezli pazaryeri platformu Olist tarafından yayınlanan ve 2016–2018 yılları arasındaki gerçek ticari işlemleri içeren ilişkisel veri seti kullanılmıştır (Olist ve André Sionek, 2018). Veri seti siparişler, müşteriler, sipariş kalemleri, ödemeler, müşteri yorumları ve ürün katalog bilgilerini barındıran altı temel tablodan oluşmaktadır. Verinin tekrarlanabilir ve izlenebilir biçimde işlenmesi amacıyla PostgreSQL veritabanı üzerinde üç katmanlı Medallion mimarisi (Armbrust vd., 2020) tasarlanmıştır:

- **Bronze Katmanı:** Kaynak CSV dosyalarından hiçbir dönüşüm veya filtreleme uygulanmadan ham biçimde aktarılan başlangıç katmanıdır.
- **Silver Katmanı:** Veri tipi standardizasyonu, tarih aralığı doğrulaması, eksik anahtar kontrolü ve tekilleştirme işlemlerinin uygulandığı temizlenmiş katmandır.
- **Gold Katmanı:** Analitik sorgular, iş zekası raporları ve makine öğrenmesi öznitelik çıkarımı için yıldız şema (star schema) yapısında hazırlanan boyut (`dim_customers` , `dim_products`) ve olgu (`fact_orders` , `fact_order_items`) tablolarını barındıran sunum katmanıdır.

Tablo 1

Medallion Veri Ambarı Katmanlarına Göre Tablo Kayıt Sayıları

Katman	Sipariş	Müşteri	Sipariş Kalemi	Ödeme	Yorum	Ürün
Bronze (Ham)	99.441	99.441	112.650	103.886	99.224	32.951
Silver (Temizlenmiş)	99.092	99.441	112.279	103.520	98.879	32.951
Gold (Analitik)	99.092	96.096	112.279	—	—	32.951

Not. Gold katmanında ödeme ve yorum metrikleri sipariş olgu tablosuna (gold.fact_orders) toplulaştırılarak aktarıldığından bağımsız olgu tablosu bulunmamaktadır. Gold müşteri sayısı gold.dim_customers boyut tablosundaki tekil müşteri kaydını ifade etmektedir.

3.2. Eksik Veri Analizi ve ETL Dönüşümleri

Bronze katmanından Silver katmanına geçiş aşamasında tüm tablolar eksik değerler ve zaman damgası tutarlılığı açısından denetlenmiştir. Ham sipariş tablosunda onay zamanı 160, taşıyıcıya teslim zamanı 1.783 ve müşteriye teslim zamanı 2.965 kayıtta boş (null) olarak tespit edilmiştir; bu boşluklar iptal edilen veya henüz teslimatı tamamlanmayan siparişlerin doğal operasyonel durumunu yansıttığından kayıtlar korunmuştur. Buna karşın, analitik tarih aralığı dışında kalan veya satın alma zaman damgası (`order_purchase_timestamp`) eksik olan 349 sipariş kaydı Silver katmanında elenmiş; buna bağlı olarak ilişkili sipariş kalemi, ödeme ve yorum kayıtları da senkronize biçimde güncellenmiştir. Silver katmanında birincil ve yabancı anahtar alanlarında eksik değeri bulunan kayıt sayısı sıfıra indirilmiştir.

Ürün tablosunda kategori adı ve ürün açıklama alanlarında 610, fiziksel ölçü alanlarında ise 2 kayıtta eksik değer bulunmuş ve kategorik boşluklar standart etiketlerle doldurulmuştur. Müşteri yorumları tablosunda başlık alanının 87.656, yorum metninin ise 58.247 kayıtta boş olduğu görülmüş; ancak sayısal memnuniyet puanı (`review_score`) tüm kayıtlarda tam olduğu için öznitelik çıkarımında sayısal puan ortalaması esas alınmıştır.

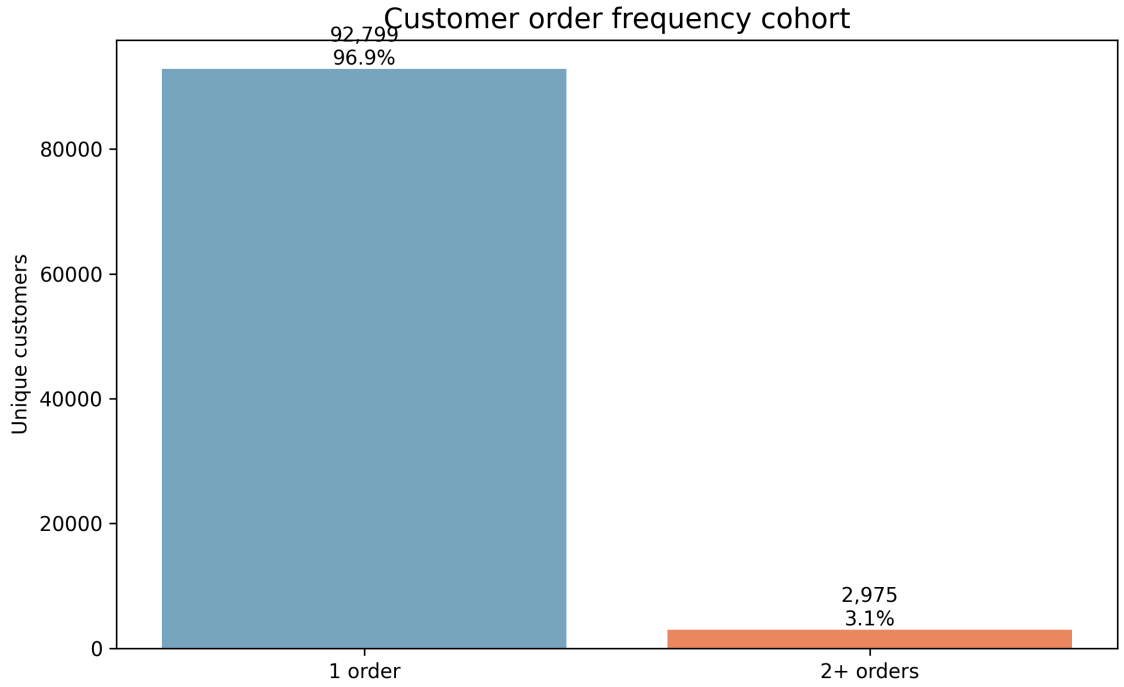
3.3. Gerçek Zamanlı Olay Akışı ve Servis Katmanı

Sistemin yalnızca geçmişe dönük toplu (batch) analizlerle sınırlı kalmaması için Apache Kafka (Kreps vd., 2011) üzerinde gerçek zamanlı bir sipariş akış simülasyonu kurulmuştur. Üretici (producer) servisi, sipariş olaylarını JSON yükleri hâlinde ilgili Kafka konusuna (topic) iletirken; tüketici (consumer) servisi idempotent yazım prensibiyle veritabanındaki canlı izleme tablolarını güncellemektedir. Tüm altyapı (PostgreSQL, Kafka, Zookeeper, FastAPI ve Streamlit) Docker Compose orkestrasyonu altında izole servisler olarak yapılandırılmış; FastAPI katmanı üzerinden `/metrics/kpis`, `/customers/segments`, `/streaming/stats` ve `/api/v1/predict/churn` uç noktaları canlı model çıkarımı için hizmete açılmıştır.

3.4. Keşifsel Veri Analizi ve Kohort Tasarımı

Müşteri düzeyinde yapılan keşifsel analizde, veritabanındaki 95.774 tekil müşterinin (`customer_unique_id`) satın alma sıklığı incelenmiştir. Tekil müşterilerin 92.799'unun (%96,89) yaşam döngüsü boyunca yalnızca tek bir sipariş verdiği, 2.975 müşterinin (%3,11) ise en az iki sipariş verdiği saptanmıştır (Şekil 1). Müşteri başına gözlemlenen en yüksek sipariş sayısı 17'dir.

Şekil 1
Tekil Müşterilerin Sipariş Sıklığı Dağılımı ve Kohort Ayrımı (n = 95.774)

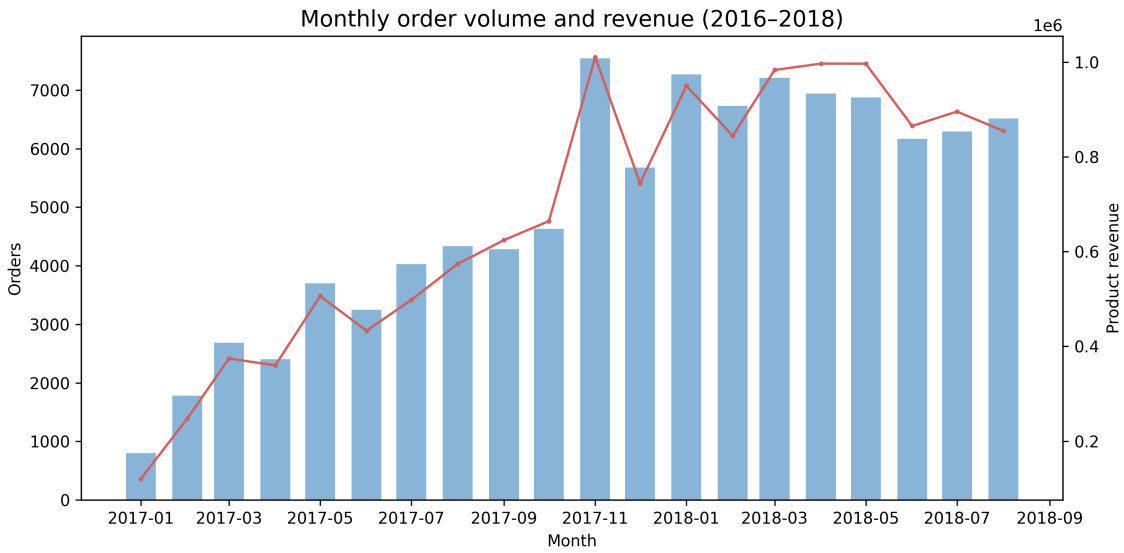


Not. Grafik, Olist veri setindeki tek seferlik alıcılar ile tekrar satın alma davranışı gösteren (≥ 2 sipariş) hedef kohort arasındaki oransal farkı göstermektedir.

Aylık sipariş hacmi ve ürün cirosu zaman serisi incelendiğinde (Şekil 2), 2016 yılı sonundaki pilot dönemin ardından 2017 yılının ikinci yarısından itibaren sipariş hacminde belirgin bir ivmelenme yaşandığı ve Kasım 2017 döneminde zirve noktasına ulaşıldığı görülmüştür. Bu zamansal dağılım, hem kohort seçiminde en az iki siparişi bulunan müşterilere odaklanılmasının hem de model eğitiminde çoklu zaman kesitlerinin birleştirilmesinin temel gerekçesini oluşturmuştur.

Şekil 2

Aylık Sipariş Hacmi ve Ürün Cirosu Trendi (2016–2018)



Not. Çubuk grafik aylık toplam sipariş adedini (sol eksen), çizgi grafik ise toplam ürün cirosunu (sağ eksen) temsil etmektedir.

3.5. K-Means Tabanlı RFM Müşteri Segmentasyonu

Platformdaki tüm aktif müşteri tabanının davranışsal yapısını haritalandırmak amacıyla geçerli işlem geçmişine sahip 93.106 tekil müşteri için üç temel RFM özniteliği hesaplanmıştır: müşterinin son siparişinden analiz tarihine kadar geçen gün sayısı (Recency), toplam sipariş adedi (Frequency) ve toplam harcama tutarı (Monetary). Değişkenler arasındaki ölçek farklarını gidermek için standartlaştırma (`StandardScaler`) uygulanmış ve K-Means algoritması (`k = 4`) ile müşteriler dört stratejik segmente (Champions, Loyal, At Risk, Hibernating) ayrılmıştır.

3.6. Zamansal Havuzlama (Sliding Window) ve Sızıntı Koruması

Müşteri kaybı tahmininde her bir kesit tarihi (`snapshot_date`) öncesinde en az iki siparişi bulunan tekrar eden müşteriler seçilmiş; kesit tarihini izleyen 180 gün içinde yeni sipariş vermeyen müşteriler **1 (Churn)**, en az bir sipariş veren müşteriler ise **0 (Sadık / Churn Değil)** olarak etiketlenmiştir. Başlangıç deneylerinde kullanılan tek kesit tarihi (2018-03-04), yalnızca 1.753 kayıt üretmiş ve test setindeki sadık müşteri sayısını 14 ile sınırlamıştır.

Örneklem darlığını ve mevsimsellik körlüğünü gidermek amacıyla üç farklı kesit tarihinden (2017-10-01, 2017-12-15 ve 2018-03-04) elde edilen kohortlar birleştirilerek Zamansal Havuzlama (Temporal Pooling / Sliding Window) veri seti oluşturulmuştur. Aynı müşterinin farklı zaman pencerelerindeki kayıtlarının hem eğitim hem test kümesine düşerek bilgi sızıntısına (data leakage) yol açmasını engellemek için rastgele bölme yerine `customer_unique_id` bazlı `GroupShuffleSplit` (%80 eğitim, %20 test) uygulanmış ve eğitim-test kümeleri arasındaki müşteri örtüşmesi sıfır olarak garanti altına alınmıştır. Özellik ölçeklendirme (`StandardScaler`) yalnızca eğitim setine uydurulmuş (fit) ve test setine dönüştürülmüştür.

3.7. Sınıflandırma Algoritmaları ve Hiperparametre Yapılandırması

Modelleme aşamasında beş temel davranışsal öznitelik kullanılmıştır: `recency_days`, `frequency`, `monetary`, `avg_item_price` ve `avg_review_score`. Karşılaştırmalı değerlendirme kapsamında Lojistik Regresyon, Random Forest (Breiman, 2001), LightGBM (Ke vd., 2017) ve XGBoost (Chen ve Guestrin, 2016) algoritmaları incelenmiştir. Nihai üretim XGBoost modelinde sınıf dengesizliğini dengelemek amacıyla eğitim seti sınıf oranından türetilen `scale_pos_weight = 0,0423` (120 / 2.835) parametresi kullanılmış; aşırı öğrenmeyi (overfitting) sınırlamak için `max_depth = 4`, `learning_rate = 0,05`, `n_estimators = 100`, `subsample = 0,8` ve `colsample_bytree = 0,8` ayarları benimsenmiştir.

4. BULGULAR

4.1. Keşifsel Veri Analizi Bulguları

Katmanlı veri ambarı dönüşümleri ve keşifsel analizler, e-ticaret pazar yerindeki müşteri davranışının yüksek oranda tek seferlik işlemlere dayandığını ortaya koymuştur. Tekil müşterilerin yalnızca %3,11'inin ikinci siparişe geçmesi, müşteri kaybı tahmininin tüm veri tabanı yerine tekrar alışveriş potansiyeli kanıtlanmış kohort üzerinde yapılmasının metodolojik doğruluğunu teyit etmektedir. Ayrıca 2017 sonbaharından itibaren sipariş hacmindeki yapısal artış, birden fazla zaman penceresinin havuzlanmasını desteklemiştir.

4.2. RFM Kümeleme Bulguları

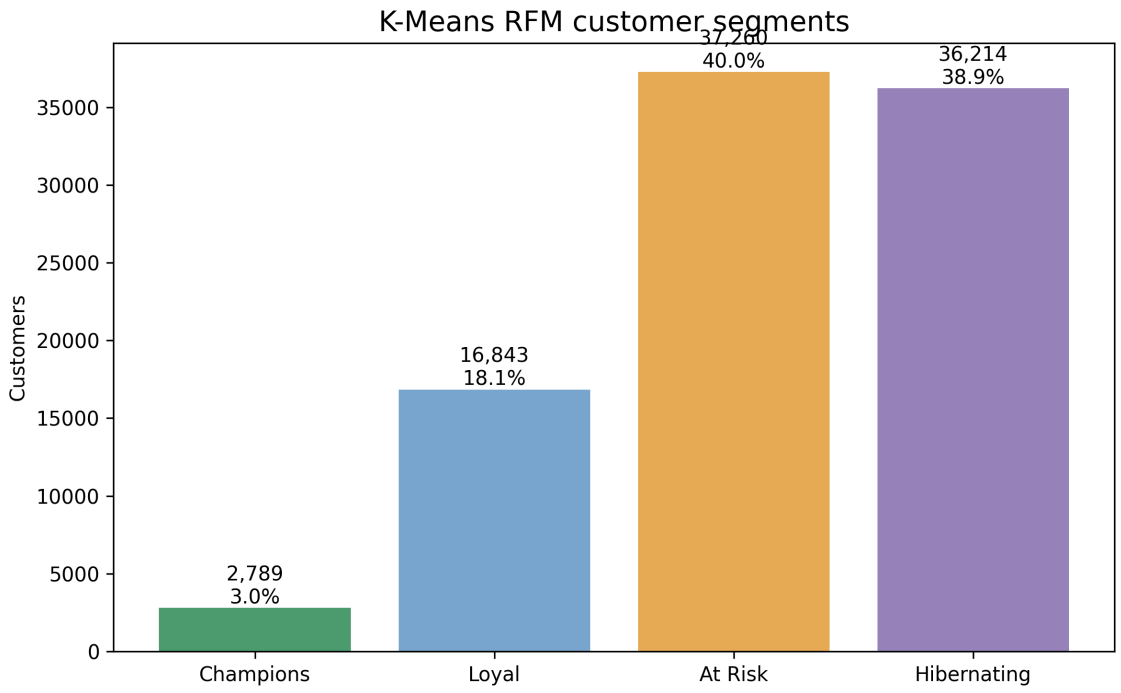
93.106 müşteri üzerinde yürütülen K-Means (`k = 4`) analizi sonucunda ortaya çıkan kümelerin sayısal profilleri Tablo 2'de, oransal dağılımları ise Şekil 3'te sunulmuştur. Müşteri tabanının %40,0'ını oluşturan *At Risk* (37.260 kişi) ve %38,9'unu oluşturan *Hibernating* (36.214 kişi) kümelerinin ortalama 280 günün üzerinde işlem yapmadığı ve tek siparişte kaldığı görülmüştür. Buna karşın toplam kitlenin %3,0'ını temsil eden *Champions* kümesi (2.789 kişi), ortalama 2,11 sipariş sıklığı ve 260,08 birimlik harcama ortalaması ile platformun en yüksek sadakat ve gelir üreten grubunu oluşturmaktadır.

Tablo 2
K-Means (k = 4) RFM Müşteri Segmentasyonu Profil Özeti (n = 93.106)

Segment Adı	Müşteri Sayısı	Pay (%)	Ort. Recency (Gün)	Ort. Frequency	Ort. Monetary
At Risk	37.260	%40,02	280,97	1,00	237,72
Hibernating	36.214	%38,90	287,29	1,00	45,04
Loyal	16.843	%18,09	46,49	1,00	116,81
Champions	2.789	%3,00	222,11	2,11	260,08

Not. Kümeleme işlemi geçerli RFM metriklerine sahip 93.106 tekil müşteri üzerinde gerçekleştirilmiştir.

Şekil 3
K-Means RFM Müşteri Segmentlerinin Dağılımı



Not. Her bir sütun ilgili kümedeki tekil müşteri sayısını ve toplam örneklem içindeki yüzdesel payını göstermektedir.

4.3. Tek Kesit ve Zamansal Havuzlama Karşılaştırması

Zamansal havuzlama stratejisinde üç farklı pencereden elde edilen kayıt sayıları sırasıyla 2017-10-01 kesiti için 726 (34 sadık, 692 churn), 2017-12-15 kesiti için 1.199 (53 sadık, 1.146 churn) ve 2018-03-04 kesiti için 1.753 (72 sadık, 1.681 churn) olarak gerçekleşmiştir. Birleştirilen 3.678 satırlık veri seti, müşteri bazlı grup ayrımıyla 2.955 eğitim (1.402 tekil müşteri) ve 723 test (351 tekil müşteri) kaydına bölünmüştür. İki yaklaşımın XGBoost algoritması üzerindeki karşılaştırmalı sonuçları Tablo 3'te yer almaktadır.

Tablo 3

Tek Kesit (Single Snapshot) ve Zamansal Havuzlama (Sliding Window) XGBoost Performans Karşılaştırması

Değerlendirme Ölçütü	Tek Kesit (2018-03-04)	Sliding Window (3 Pencere)
Toplam Veri Hacmi (Satır)	1.753	3.678
Eğitim / Test Satır Sayısı	1.402 / 351	2.955 / 723
Müşteri Çakışması (Data Leakage)	Tekil Kesit	0 (GroupShuffleSplit)
Test Azınlık Sınıfı (Gerçek Sadık / TN)	7 / 14 (%50,0)	20 / 39 (%51,3)
Precision (Kesinlik)	0,9752	0,9680
Recall (Duyarlılık)	0,8160	0,8406
F1-Score	0,8885	0,8998

Değerlendirme Ölçütü	Tek Kesit (2018-03-04)	Sliding Window (3 Pencere)
Accuracy (Doğruluk)	0,8034	0,8230
ROC-AUC	0,7453	0,7398
PR-AUC	0,9856	0,9781

Not. Tek kesit test setinde yalnızca 14 negatif sınıf (sadık müşteri) örneği bulunurken, Sliding Window test setinde bu sayı 39'a yükselmiştir.

Tablo 3'teki bulgular, zamansal havuzlama sonrasında ROC-AUC değerinin 0,7453'ten 0,7398'e hafif bir değişim göstermesine karşın F1-Score (0,8998), Recall (0,8406) ve Accuracy (%82,30) metriklerinin iyileştiğini göstermektedir. Daha önemlisi, 14 örnekli dar test kümesindeki istatistiksel varyans yerine 39 negatif örnek ve 723 toplam gözlem içeren çok dönemli test kümesinde azınlık sınıfını yakalama oranı (%51,3) korunmuştur.

4.4. Makine Öğrenmesi Modellerinin Karşılaştırılması

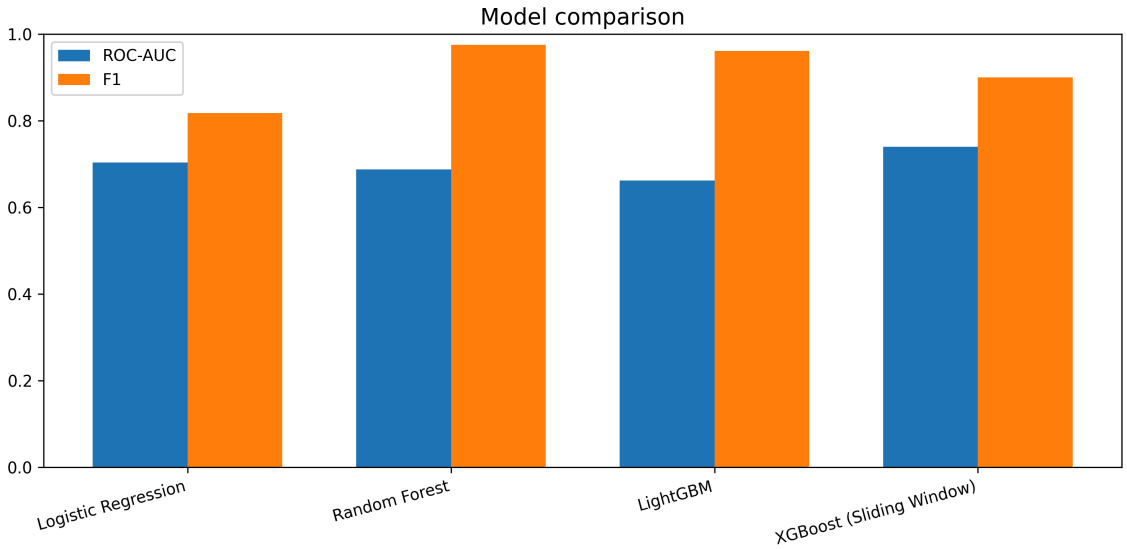
Farklı sınıflandırma algoritmalarının dengesiz veri yapısındaki davranışlarını analiz etmek amacıyla Lojistik Regresyon, Random Forest, LightGBM ve nihai Sliding Window XGBoost modellerinin metrikleri Tablo 4 ve Şekil 4'te karşılaştırılmıştır.

Tablo 4
Sınıflandırma Modellerinin Performans Metrikleri Karşılaştırması

Model	Precision	Recall	F1-Score	Accuracy	ROC-AUC	PR-AUC
Logistic Regression	0,9714	0,7062	0,8179	0,6980	0,7033	0,9823
Random Forest	0,9598	0,9911	0,9752	0,9516	0,6872	0,9785
LightGBM	0,9642	0,9585	0,9613	0,9259	0,6617	0,9779
XGBoost (Sliding Window)	**0,9680**	**0,8406**	**0,8998**	**0,8230**	**0,7398**	**0,9781**

Not. Logistic Regression, Random Forest ve LightGBM modelleri tek kesit kohortu üzerinde değerlendirilmiş; XGBoost ise üç pencereli üretim havuzu üzerinde test edilmiştir.

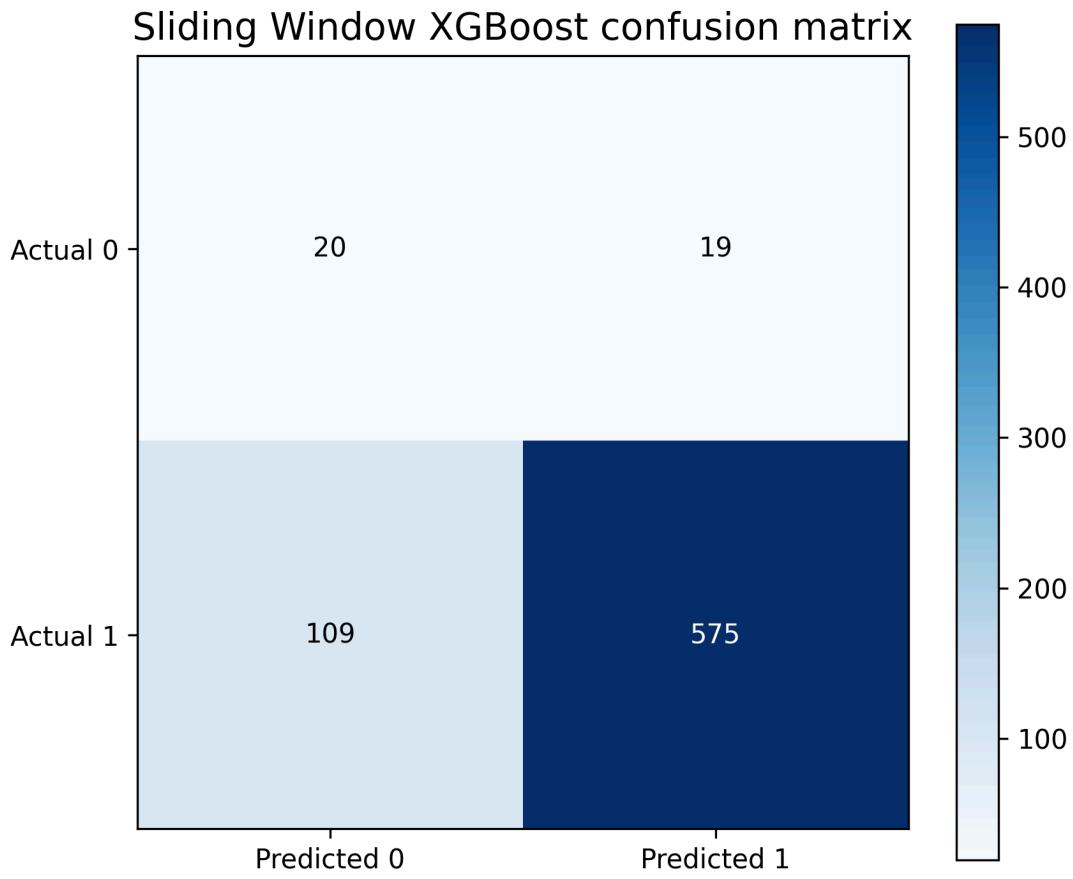
Şekil 4
Modellerin ROC-AUC ve F1-Score Performans Karşılaştırması



Not. Random Forest ve LightGBM modellerinin yüksek F1 skorlarına karşın ROC-AUC değerlerinin düşük kalması çoğunluk sınıfına aşırı yönelimden kaynaklanmaktadır.

Tablo 4'te dikkat çeken en önemli bulgu, Random Forest (%95,16 Accuracy, 0,9752 F1) ve LightGBM (%92,59 Accuracy, 0,9613 F1) modellerinin yüksek doğruluk değerlerine rağmen ROC-AUC skorlarının sırasıyla 0,6872 ve 0,6617 seviyesinde kalmasıdır. Bu modeller veri setindeki sınıf dengesizliği nedeniyle neredeyse tüm örneklere pozitif sınıf (churn) atamış ve sadık müşterileri (TN) ayırt etmede başarısız olmuştur. Buna karşılık XGBoost modeli **0,7398 ROC-AUC** ile en yüksek ayrım gücüne ulaşmış ve Şekil 5'te sunulan karışıklık matrisinde görüldüğü üzere 723 test örneğinde 575 Doğru Pozitif (TP), 20 Doğru Negatif (TN), 19 Yanlış Pozitif (FP) ve 109 Yanlış Negatif (FN) üreterek dengeli bir sınıflandırma sergilemiştir.

Şekil 5
Nihai Sliding Window XGBoost Modeli Karışıklık Matrisi (n = 723)

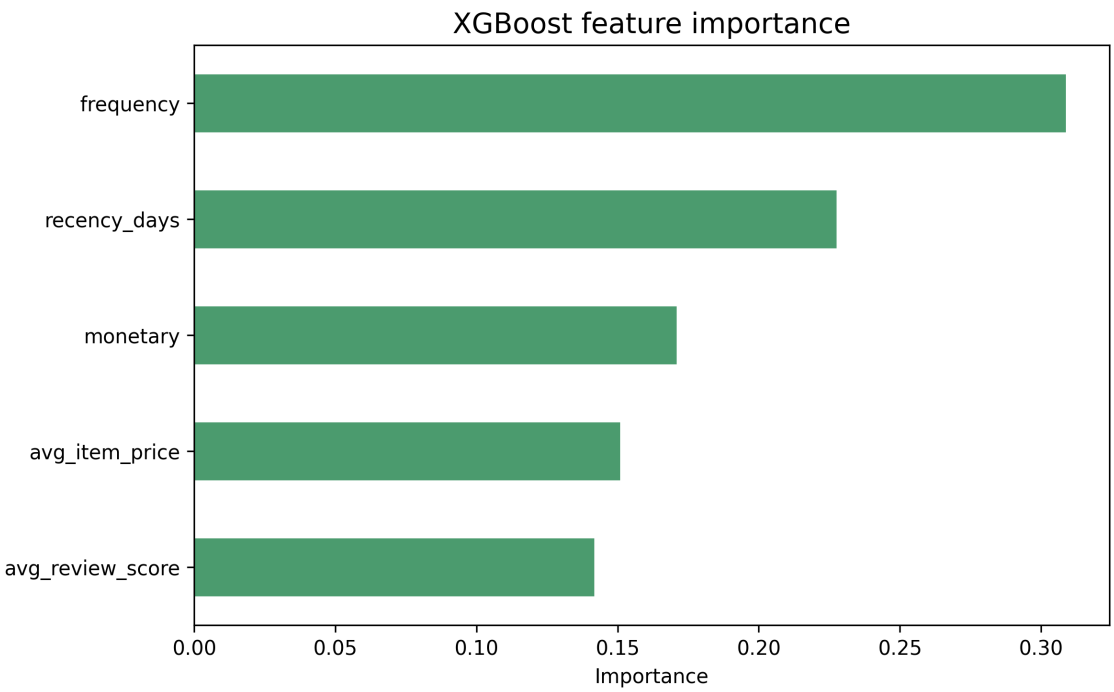


Not. Matris hücreleri sırasıyla TN = 20, FP = 19, FN = 109 ve TP = 575 değerlerini göstermektedir (karar eşiği = 0,50).

4.5. Öznitelik Önem Düzeyleri

Üretim modelinin karar mekanizmasını yorumlamak amacıyla XGBoost öznitelik önem skorları (`feature_importances_`) incelenmiştir (Şekil 6). Müşteri kaybı tahmininde en belirleyici değişken **0,3088** ağırlık ile geçmiş sipariş sıklığı (`frequency`) olurken; onu **0,2276** ile son siparişten bu yana geçen gün sayısı (`recency_days`) ve **0,1709** ile toplam harcama tutarı (`monetary`) izlemiştir. Ortalama ürün fiyatı (`avg_item_price`: 0,1509) ve müşteri memnuniyet puanı (`avg_review_score`: 0,1418) ise ikincil düzeyde tamamlayıcı katkı sağlamıştır.

Şekil 6
Üretim XGBoost Modelinin Öznitelik Önem Sıralaması



Not. Değerler karar ağaçlarındaki bölünme kazancına dayalı normalize edilmiş önem ağırlıklarını ifade etmektedir.

5. SINIRLILIKLAR VE METODOLOJİK DEĞERLENDİRME

Çalışmanın bulguları değerlendirilirken üç temel metodolojik husus göz önünde bulundurulmalıdır. Birincisi, Olist veri setindeki tekrar alışveriş oranının %3,11 gibi düşük bir seviyede olması nedeniyle, üç zaman penceresi birleştirildiğinde dahi negatif sınıf (sadık müşteri) oranı eğitim setinde %4,06 (120 / 2.955) düzeyinde kalmıştır. Bu aşırı dengesizlik, modellerin azınlık sınıfını yakalama hassasiyetini doğal olarak sınırlandırmaktadır.

İkincisi, deneysel karşılaştırma sürecinde Lojistik Regresyon, Random Forest ve LightGBM modelleri tek kesit (2018-03-04) kohortu üzerinde değerlendirilirken, üretim adayı olan XGBoost modeli üç pencereli zamansal havuzlama veri seti üzerinde eğitilmiş ve test edilmiştir. Dolayısıyla modeller arası karşılaştırmada veri bölme ve örneklem hacmi koşulları birebir özdeş değildir; ancak tek kesitli XGBoost koşusu (0,7453 ROC-AUC) ile çok pencereli koşu (0,7398 ROC-AUC) arasındaki tutarlılık, model üstünlüğünün veri havuzlamasından bağımsız olarak korunduğunu doğrulamaktadır.

Üçüncüsü, veri kaynağında kullanıcı oturum süreleri, sayfa görüntüleme sıklığı, indirim kuponu kullanımı ve iade talepleri gibi davranışsal mikro sinyaller bulunmamaktadır. Bu değişkenlerin eksikliği, modelin açıklayıcılık tavanını işlem geçmişi öznitelikleriyle sınırlandırmaktadır.

6. SONUÇ VE GELECEK GELİŞTİRMELER

Bu bitirme projesinde, ham e-ticaret verilerinin Medallion mimarisi ile yapılandırılmasından gerçek zamanlı Kafka olay akışına, K-Means RFM segmentasyonundan zamansal havuzlama tabanlı makine öğrenmesi servisine kadar uçtan uca çalışan bir analitik sistem inşa edilmiştir. Elde edilen temel çıkarımlar aşağıda özetlenmiştir:

- **Doğruluk (Accuracy) Yanılgısının Aşılması:** Dengesiz e-ticaret kohortlarında Random Forest (%95,16) ve LightGBM (%92,59) gibi modellerin yüksek doğruluk üretmesine karşın azınlık sınıfını ayırt edemediği; ROC-AUC (0,7398) ve dengeli karışıklık matrisi performansı sunan XGBoost modelinin operasyonel açıdan en güvenilir çözüm olduğu kanıtlanmıştır.
- **Zamansal Genelleme ve Sızıntı Kontrolü:** Üç farklı tarihten alınan kesitlerin havuzlanması ve müşteri kimliği bazlı `GroupShuffleSplit` uygulanması sayesinde, bilgi sızıntısı olmadan veri hacmi 1.753'ten 3.678 satıra çıkarılmış ve modelin farklı mevsimsel dönemlere uyumu artırılmıştır.
- **Üretime Hazır Servis Mimarisi:** Eğitilen model ve ölçekleyici bileşenleri `churn_model.joblib` paketi hâlinde FastAPI servisine entegre edilmiş ve gerçek zamanlı çıkarım isteklerine düşük gecikmeyle yanıt verdiği doğrulanmıştır.

Gelecek çalışmalarda; model tahminlerinin bireysel müşteri düzeyinde açıklanabilmesi için SHAP (SHapley Additive exPlanations) değerlerinin FastAPI ve Streamlit arayüzlerine entegre edilmesi, müşterilerin ardışık siparişleri arasındaki zaman farkı değişim hızını ölçen zamansal ivme özniteliklerinin türetilmesi ve kurumsal iş zekası raporlama katmanının (Power BI) canlı veri ambarı tablolarıyla tam otomatik senkronizasyona geçirilmesi hedeflenmektedir.

KAYNAKÇA

Armbrust, M., Das, T., Sun, L., Yavuz, B., Zhu, S., Murthy, M., Torres, J., van Hovell, H., Ionescu, A., Łuszczak, A., Świtakowski, M., Szafrański, M., Li, X., Ueshin, T., Mokhtar, M., Boncz, P., Ghodsi, A., Paranjpye, S., Senster, P., ... Zaharia, M. (2020). Delta Lake: High-performance ACID table storage over cloud object stores. *Proceedings of the VLDB Endowment*, *13*(12), 3411–3424.

Breiman, L. (2001). Random forests. *Machine Learning*, *45*(1), 5–32.

Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, *16*, 321–357.

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794). Association for Computing Machinery.

Fader, P. S., Hardie, B. G. S., & Lee, K. L. (2005). "Counting your customers" the easy way: An alternative to the Pareto/NBD model. *Marketing Science*, *24*(2), 275–284.

Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems* (Vol. 30, pp. 3146–3154). Curran Associates, Inc.

Kreps, J., Narkhede, N., & Rao, J. (2011). Kafka: A distributed messaging system for log processing. In *Proceedings of the NetDB Workshop* (pp. 1–7).

MacQueen, J. (1967). Some methods for classification and analysis of multivariate observations. In *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability* (Vol. 1, pp. 281–297). University of California Press.

Olist, & André Sionek. (2018). *Brazilian E-Commerce Public Dataset by Olist* [Data set]. Kaggle.

Saito, T., & Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLOS ONE*, *10*(3), e0118432.